

T.C.
SAKARYA UYGULAMALI BİLİMLER ÜNİVERSİTESİ
HENDEK MESLEK YÜKSEKOKULU
MAKİNE VE METAL TEKNOLOJİLERİ BÖLÜMÜ
İMALAT YÜRÜTME SİSTEMLERİ OPERATÖRLÜĞÜ PROGRAMI

Derin öğrenme ve Görüntü İşleme Tabanlı Görsel Kalite Kontrol Sistemlerinde
Kullanılan Kusur Tespit Yöntemleri

Hazırlayanlar

24231401016 Muhammed Arda Sarı
24231401010 Mehmet Ceran

Danışmanı : **Öğretim Görevlisi Serkan Mutlu**

Aralık 2025

İÇİNDEKİLER

İçindekiler

Özet

Kısaltmalar Listesi

GİRİŞ

Endüstriyel Kalite Kontrol ve Kalite 4.0 Kavramı

Büyük Veri (Big Data) ve Üretimde Veri Analitiği

Çalışmanın Amacı ve Kapsamı

TEORİK ALTYAPI: SAYISAL GÖRÜNTÜ İŞLEME

Sayısal Görüntü ve Piksel Kavramı

Görüntü Oluşturma Donanımları: CCD Sensörler

Analogdan Dijitale Dönüşüm: Kuantalama (Quantization)

Görüntü Analiz Teknikleri: Histogram Analizi

YAPAY ZEKA VE DERİN ÖĞRENME YAKLAŞIMLARI

Makine Öğrenmesi (Machine Learning) Temelleri

Derin Öğrenme (Deep Learning) ve Sinir Ağları

Öğrenme Türleri

Denetimli Öğrenme (Supervised Learning)

Denetimsiz Öğrenme ve Anomali Tespiti

Transfer Öğrenme (Transfer Learning)

KULLANILAN MİMARİLER VE TEKNİKLER

İlgi Alanı (ROI- Region of Interest) Belirleme

Evrişimsel Sinir Ağları (CNN)

Görüntü Bölütleme (Segmentation) Mimarileri: U-Net ve Autoencoders

Nesne Tespit Algoritmaları: YOLO

MATERYAL VE YÖNTEM: METAL YÜZEY UYGULAMASI

Veri Seti Hazırlığı ve Ön İşleme

Veri Dengesizliği (Data Imbalance) Problemi

Veri Artırma

Model Eğitimi ve Hiperparametreler

Donanım Entegrasyonu (Gömülü Sistemler)

BULGULAR VE TARTIŞMA

Model Başarım Kriterleri

IoU (Intersection over Union) Değerleri

Yalancı Pozitif (False Positive) ve Yalancı Negatif (False Negative) Analizi

Karşılaşılan Zorluklar: Aşırı Öğrenme (Overfitting)

SONUÇ VE ÖNERİLER

KAYNAKÇA

ÖZET

Endüstri 4.0 ve dijital dönüşüm süreçleri, üretim hatlarındaki kalite kontrol mekanizmalarını kökten değiştirerek “Kalite 4.0” kavramını ortaya çıkarmıştır. Geleneksel insan gözüne dayalı denetimlerin yavaş, öznel ve hataya açık olması nedeniyle, derin öğrenme tabanlı otonom kusur tespit sistemlerine duyulan ihtiyaç artmıştır. Bu çalışmada, sayısal görüntü işleme teknikleri ve Evrişimsel Sinir Ağları kullanılarak geliştirilen endüstriyel görsel kalite kontrol yöntemleri incelenmiştir. Özellikle metal sanayisinde sıkça karşılaşılan yüzey hatalarının (çatlak, tufal, çizik vb.) tespiti için YOLO gibi gerçek zamanlı nesne tespit mimarileri ve NEU-DET veri seti üzerindeki uygulamalar ele alınmıştır. Çalışma kapsamında; görüntülerin CCD sensörlerden alınarak sayısal matrislere dönüştürülmesi, histogram analizi ve ilgi alanı belirleme süreçleri teknik altyapı olarak sunulmuştur. Ayrıca, algoritmaların başarısını etkileyen veri dengesizliği ve aşırı öğrenme problemleri ile bunlara çözüm olarak sunulan veri artırma ve transfer öğrenme yöntemleri tartışılmıştır. Sistemin endüstriyel uygulanabilirliği açısından, eğitilen modellerin NVIDIA Jetson Nano gibi gömülü sistemler üzerindeki gerçek zamanlı performansı değerlendirilmiştir. Literatür taraması sonucunda, derin öğrenme tabanlı sistemlerin yüksek IoU değerleri ve düşük hatalı tespit oranları ile üretim verimliliğini artırdığı ve maliyetleri düşürdüğü görülmüştür.

KISALTMALAR LİSTESİ

AI: Yapay Zekâ (Artificial Intelligence)

ANN: Yapay Sinir Ağları (Artificial Neural Networks)

CCD: Yük Bağlı Ayrıştırıcı (Charge-Coupled Device)

CMOS: Bütünleyici Metal Oksit Yarı İletken (Complementary Metal-Oxide-Semiconductor)

CNN: Evrişimsel Sinir Ağları (Convolutional Neural Networks)

DL: Derin Öğrenme (Deep Learning)

FN: Yalancı Negatif (False Negative)

FP: Yalancı Pozitif (False Positive)

FPS: Saniye Başına Kare Sayısı (Frames Per Second)

GPU: Grafik İşlem Birimi (Graphics Processing Unit)

IoT: Nesnelerin İnterneti (Internet of Things)

IIoT: Endüstriyel Nesnelerin İnterneti (Industrial Internet of Things)

IoU: Kesişim Bölü Birleşim (Intersection over Union)

mAP: Ortalama Hassasiyet Değeri (mean Average Precision)

ML: Makine Öğrenmesi (Machine Learning)

NEU-DET: Northeastern Üniversitesi Metal Yüzey Kusur Veri Seti (Northeastern University Defect Database)

OEE: Genel Ekipman Etkinliği (Overall Equipment Effectiveness)

PLC: Programlanabilir Mantık Denetleyici (Programmable Logic Controller)

RGB: Kırmızı-Yeşil-Mavi Renk Uzayı (Red-Green-Blue)

ROI: İlgi Alanı (Region of Interest)

TP: Doğru Pozitif (True Positive)

TPU: Tensör İşlem Birimi (Tensor Processing Unit)

TN: Doğru Negatif (True Negative)

YOLO: Tek Seferde Bak (You Only Look Once)

GİRİŞ

Endüstriyel üretimde rekabetin artmasıyla birlikte, ürün kalitesinin sürekliliği ve üretim hatalarının minimize edilmesi kritik bir önem kazanmıştır. Geleneksel üretim yöntemlerinde kalite kontrol süreçleri genellikle insan gözüne dayalı manuel denetimlerle veya sınırlı kabiliyetlere sahip sensörlerle yapılmaktaydı. Ancak Endüstri 4.0 devrimi ile birlikte fabrikaların dijitalleşmesi, kalite kontrol süreçlerini de kökten değiştirmiş ve "Kalite 4.0" kavramını ortaya çıkarmıştır. Bu yeni dönemde, yapay zeka, büyük veri ve nesnelerin interneti (IoT) gibi teknolojiler, hataları sadece tespit etmekle kalmayıp, oluşmadan önce tahmin etmeyi mümkün kılmaktadır.

Endüstriyel Kalite Kontrol ve Kalite 4.0 Kavramı

Endüstri 4.0; insansız üretimin yapıldığı, robotik sistemler ile otomasyonun üretimin her aşamasında sağlandığı, siber-fiziksel sistemlerin ve akıllı fabrikaların ön plana çıktığı bir süreçtir. Bu dönüşümün doğal bir sonucu olarak kalite yönetimi de evrim geçirerek **Kalite 4.0** adını almıştır. Kalite 4.0, geleneksel kalite yöntemlerinin (insan, makine, materyal) Endüstri 4.0 teknolojileriyle (yapay zekâ, makine öğrenimi, bulut bilişim) entegre edilmesidir.

Geleneksel kalite anlayışı genellikle reaktif bir yaklaşım sergileyerek hataları üretimden sonra ayıklamaya odaklanırken; Kalite 4.0, proaktif bir yaklaşımla hatanın kaynağını verilerle analiz edip önlemeyi hedefler. Amaç, kalitenin daha düşük maliyetle ve müşteri beklentilerinin ötesinde bir mükemmeliyetle sağlanmasıdır. Özellikle metal ve çelik sanayi gibi ağır sanayi kollarında, yüzey kusurlarının (çatlak, çizik vb.) insan gözüyle tespitinin zor ve yorucu olması, derin öğrenme tabanlı otonom kalite kontrol sistemlerini zorunlu hale getirmiştir.

Büyük Veri (Big Data) ve Üretimde Veri Analitiği

Modern üretim tesislerinde makineler, sensörler ve kameralar aracılığıyla saniyede binlerce veri üretilmektedir. "Büyük Veri" olarak adlandırılan bu devasa bilgi yığını, üretim hatlarının verimliliğini artırmak için en değerli kaynaktır. Kalite 4.0 kapsamında toplanan bu veriler, sadece geçmişte ne olduğunu raporlamak için değil, gelecekte ne olacağını tahmin etmek (kestirimci kalite) için analiz edilir.

Görsel kalite kontrol sistemleri de bu büyük verinin en önemli kaynaklarından birini oluşturur. Üretim bandından geçen her bir ürünün yüksek çözünürlüklü görüntüsü, işlenmesi gereken bir veri paketidir. Bu görüntülerin derin öğrenme algoritmalarıyla anlık olarak işlenmesi, üretimdeki sapmaların milisaniyeler içinde fark edilmesini ve hatalı ürünün müşteriye ulaşmadan ayrılmasını sağlar.

Çalışmanın Amacı ve Kapsamı

Metal yüzeylerdeki kusurlar endüstriyel ürünlerin kalitesini doğrudan etkilemektedir ve bu nedenle üretim sonrası hata tespiti hayati bir öneme sahiptir. Bu çalışmanın temel amacı, çelik yüzeylerde sıkça karşılaşılan üretim kusurlarının (çizik, yama, tufal vb.) tespiti için derin öğrenme tabanlı yöntemlerin etkinliğini incelemektir.

Çalışma kapsamında, özellikle **YOLO** gibi gerçek zamanlı nesne tespit algoritmalarının başarımı ve bu algoritmaların endüstriyel ortamlarda kullanılabilirliği ele alınmıştır. Ayrıca, geliştirilen yapay zekâ modellerinin yüksek işlem gücü gerektiren bilgisayarlar yerine, üretim hattına entegre edilebilen **NVIDIA Jetson Nano** gibi gömülü sistemler üzerinde nasıl çalıştırılabileceği araştırılmıştır. Bu sayede, teorik bilginin pratik bir endüstriyel uygulamaya dönüşümü ortaya konulmuştur.

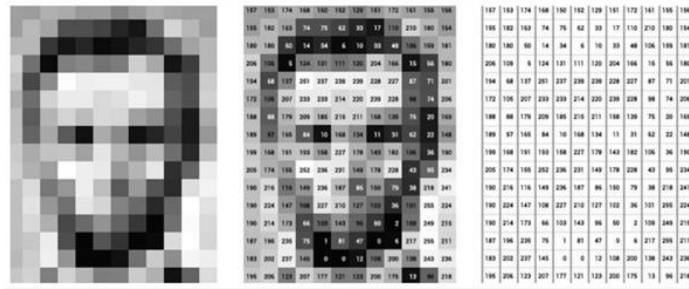
TEORİK ALTYAPI: SAYISAL GÖRÜNTÜ İŞLEME

Endüstriyel kalite kontrol sistemlerinin başarısı, sahadan alınan görüntülerin kalitesine ve bu görüntülerin bilgisayar ortamında nasıl temsil edildiğine bağlıdır. Bu bölümde, görüntü işleme teknolojisinin temel yapı taşları olan sayısal görüntü, donanım ve analiz teknikleri incelenmiştir.

Sayısal Görüntü ve Piksel Kavramı

Bilgisayarlı görü sistemlerinde bir görüntü, insan gözünün algıladığı gibi sürekli bir yapı değil, sayısal değerlerden oluşan ayrık (discrete) bir matristir. Bu matrisin en küçük yapı taşına **Piksel** (Picture Element) adı verilir. Bir görüntü, matematiksel olarak $f(x, y)$ şeklinde iki boyutlu bir fonksiyon olarak ifade edilir; burada x ve y uzamsal koordinatları, f ise o noktadaki parlaklık değerini (intensity) temsil eder.

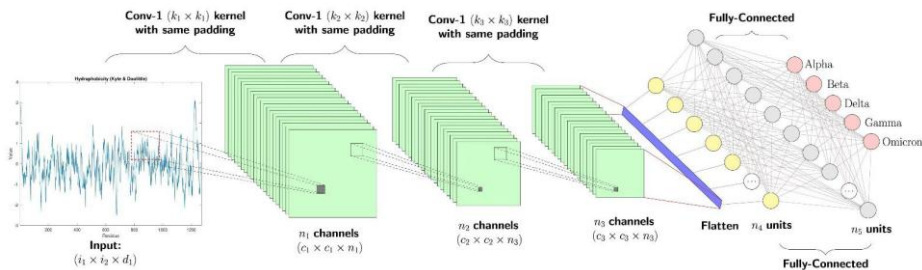
Endüstriyel uygulamalarda genellikle 8-bitlik gri seviyeli (grayscale) görüntüler kullanılır. Bu formatta her bir piksel, 0 (tam siyah) ile 255 (tam beyaz) arasında değişen bir tamsayı değeri alır. Renkli görüntülerde ise bu yapı, Kırmızı (Red), Yeşil (Green) ve Mavi (Blue) olmak üzere üç ayrı kanalın birleşiminden oluşur. Derin öğrenme algoritmaları, görüntüdeki nesneleri tanımak için bu piksel matrislerindeki sayısal örüntüleri analiz eder.



Görüntü Oluşturma Donanımları: CCD Sensörler

Kalite kontrol sürecinin ilk adımı, ürünün görüntüsünün fiziksel ortamdan dijital ortama aktarılmasıdır. Bu işlem endüstriyel kameralarda bulunan görüntü sensörleri ile gerçekleştirilir. En yaygın kullanılan sensör teknolojisi **CCD (Charge- Coupled Device)** sensörlerdir.

CCD sensörler, yüzeylerine düşen fotonları (ışık enerjisini) fotoelektrik etki prensibiyle elektrik yüküne (elektronlara) dönüştüren binlerce küçük hücreden oluşur. Bu hücreler matris yapısındadır ve her biri görüntünün bir pikseline karşılık gelir. CCD sensörler, yüksek ışık hassasiyetleri ve düşük gürültü oranları nedeniyle, metal yüzeylerdeki ince çiziklerin veya çatlakların tespit edilmesi gereken hassas endüstriyel uygulamalarda tercih edilmektedir.



Analogdan Dijitale Dönüşüm: Kuantalama (Quantization)

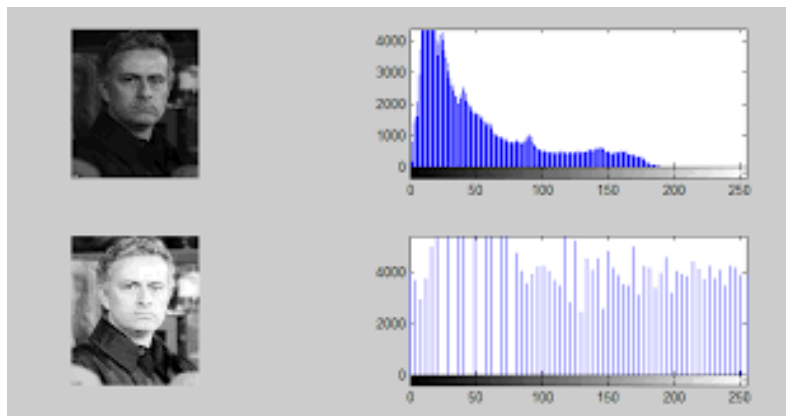
Kamera sensörleri tarafından algılanan sinyal, doğası gereği sürekli (analog). Ancak bilgisayarların veya gömülü sistemlerin bu veriyi işleyebilmesi için sinyalin sayısal hale getirilmesi gerekir. Görüntünün örneklenmesi (sampling) sonucunda elde edilen analog parlaklık değerlerinin, belirli bir bit derinliğinde (örneğin 0-255 arası) ayırık sayısal değerlere yuvarlanması işlemine **Kuantalama** denir.

Kuantalama işlemi, görüntünün kalitesini ve dosya boyutunu doğrudan etkiler. Yetersiz kuantalama, görüntüde "konturlaşma" adı verilen bozulmalara yol açarak hatalı ürün tespitine neden olabilir. Bu nedenle endüstriyel kalite kontrolde yüksek bit derinliğine sahip, doğru kuantalanmış görüntüler kullanmak, algoritmanın başarımı için kritiktir.

Görüntü Analiz Teknikleri: Histogram Analizi

Histogram, bir dijital görüntüdeki piksellerin parlaklık dağılımını gösteren grafiksel bir analiz yöntemidir. Grafiğin yatay eksenini piksel yoğunluk değerlerini (0-255), dikey eksenini ise görüntüde o değere sahip kaç adet pikselin bulunduğunu gösterir.

Derin öğrenme modellerine veri beslemeden önce yapılan ön işleme (pre-processing) aşamasında histogram analizi büyük önem taşır. Özellikle metal yüzeylerdeki parlamalar veya yetersiz aydınlatma sorunları histogram grafiğine bakılarak tespit edilir. Histogram verilerine dayanarak yapılan "Histogram Eşitleme" (Histogram Equalization) işlemi, görüntünün kontrastını artırarak kusurların (çizik, leke vb.) arka plandan daha net ayrışmasını sağlar ve yapay zekâ modelinin doğruluğunu artırır.



YAPAY ZEKA VE DERİN ÖĞRENME YAKLAŞIMLARI

Endüstriyel kalite kontrol sistemlerinde karşılaşılan karmaşık problemlerin çözümü, geleneksel kural tabanlı algoritmaların ötesine geçerek, veriden öğrenen akıllı sistemlerin kullanımını zorunlu kılmıştır. Bu bölümde, sistemin karar verme mekanizmasını oluşturan yapay zekâ ve derin öğrenme temelleri incelenmiştir.

kul (Machine Learning) Temelleri

Makine öğrenmesi, bilgisayarların açıkça programlanmadan, geçmiş verileri kullanarak bir görevi yerine getirmesini sağlayan algoritmalar bütünüdür. Geleneksel yazılımlarda bir problemin çözümü için tüm kurallar (örneğin; "piksel değeri 200'den büyükse çiziktir") insan tarafından kodlanırken; makine öğrenmesinde algoritma, girdi verileri (görüntüler) ve çıktı verileri (etiketler) arasındaki matematiksel ilişkiyi kendisi keşfeder. Endüstri 4.0 ve Kalite 4.0 vizyonu çerçevesinde makine öğrenmesi, üretim hatalarının sadece tespit edilmesinde değil, büyük veri analitiği ile hataların kök nedenlerinin anlaşılmasında ve kestirimci kalite süreçlerinde temel bir rol oynamaktadır.

Derin Öğrenme (Deep Learning) ve Sinir Ağları

Derin öğrenme, makine öğrenmesinin, insan beynindeki biyolojik nöronların çalışma prensibini taklit eden "Yapay Sinir Ağları"na (ANN- Artificial Neural Networks) dayalı bir alt dalıdır. "Derin" terimi, ağı çok sayıda gizli katmana (hidden layers) sahip olmasını ifade eder.

Geleneksel makine öğrenmesi yöntemlerinde (SVM, Karar Ağaçları vb.) görüntüden öznitelik çıkarma (feature extraction) işlemi manuel olarak yapılırken; derin öğrenme modelleri, özellikle CNN sayesinde bu öznitelikleri ham veriden otomatik olarak öğrenir. Bu yetenek, metal yüzeylerdeki karmaşık ve değişken yapıdaki kusurların (pas, ince çizik, tufal) tespitinde derin öğrenmeyi rakipsiz kılmıştır. Model, eğitildikçe düşük seviyeli özellikleri (kenarlar, köşeler) birleştirerek yüksek seviyeli özellikleri (nesne şekli, kusur tipi) tanımayı öğrenir.

Öğrenme Türleri

Endüstriyel görsel denetim sistemlerinde, mevcut verinin yapısına ve problemin tanımına göre farklı öğrenme yaklaşımları kullanılmaktadır.

Denetimli Öğrenme (Supervised Learning)

Denetimli öğrenme, modelin eğitim sürecinde hem girdi görüntülerinin hem de bu görüntülere ait doğru etiketlerin (cevap anahtarı) sisteme verildiği yöntemdir. Amaç, modelin girdi ile çıktı arasındaki fonksiyonu öğrenerek, daha önce hiç görmediği yeni bir görüntü geldiğinde doğru etiketi tahmin etmesidir.

Bu çalışmada incelenen çelik yüzey hata tespiti uygulamalarında, kusurların sınıflandırılması ve konumlarının belirlenmesi (nesne tespiti) genellikle denetimli öğrenme ile yapılır. Örneğin, YOLO (You Only Look Once) mimarisi, eğitim setindeki binlerce "çizik" ve "yama" etiketli görüntüyü analiz ederek, üretim hattındaki yeni bir üründe bu hataları yüksek doğrulukla tespit edebilmektedir.

Denetimsiz Öğrenme ve Anomali Tespiti (Unsupervised Learning / Anomaly Detection)

Denetimsiz öğrenmede, eğitim verileri herhangi bir etiket içermez; algoritmanın veriler arasındaki gizli yapıyı veya benzerlikleri kendisinin bulması beklenir. Endüstriyel kalite kontrolde bu yaklaşım genellikle **Anomali Tespiti** (Anomaly Detection) olarak karşımıza çıkar.

Fabrikalarda kusurlu ürün verisi toplamak zordur ve kusurlar öngörülemeyen şekillerde olabilir. Bu nedenle sisteme sadece "sağlam" (kusursuz) ürünlerin görüntüleri öğretilir. Model, sağlam ürünün normal dağılımını öğrendikten sonra, bu dağılıma uymayan (yani sağlam olana benzemeyen) her türlü görüntüyü "anomalî" veya "kusur" olarak işaretler. Bu yöntem, önceden tanımlanmamış veya hiç görülmemiş hata türlerinin yakalanmasında büyük avantaj sağlar.

Transfer Öğrenme (Transfer Learning)

Derin öğrenme modellerinin (özellikle derin CNN yapılarının) sıfırdan eğitilmesi için çok büyük miktarda etiketli veriye ve yüksek işlem gücüne ihtiyaç vardır. Ancak endüstriyel senaryolarda her zaman binlerce hatalı ürün fotoğrafı bulunmayabilir.

Transfer öğrenme, ImageNet gibi milyonlarca görüntü içeren büyük veri setleri üzerinde önceden eğitilmiş (pre-trained) modellerin (VGG16, ResNet, Inception vb.) ağırlıklarının alınıp, daha az veriye sahip yeni bir probleme (örneğin metal veya ahşap yüzey hatası tespiti) uyarlanmasıdır. Bu yöntemde, modelin ilk katmanları genel görsel özellikleri (kenar, doku) tanımayı zaten bildiği için, sadece son katmanlar yeni veri setiyle (çelik yüzey hataları) tekrar eğitilir (fine-tuning). Bu sayede hem eğitim süresi kısalır hem de az sayıda veriyle yüksek başarı oranlarına ulaşılır.

MİMARİLER VE TEKNİKLER

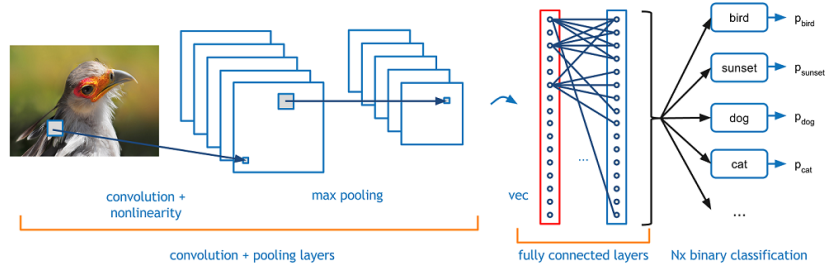
Bu bölümde, görsel kalite kontrol sistemlerinin temelini oluşturan görüntü işleme adımları ve derin öğrenme mimarileri incelenmiştir.

İlgi Alanı (ROI- Region of Interest) Belirleme

Görsel kalite kontrol sistemlerinde İlgi Alanı (ROI) belirleme, tüm görüntüyü işlemek yerine sadece üzerinde kusur aranacak spesifik bölgeye odaklanma işlemidir. Bu adım, sistemin hızını ve doğruluğunu doğrudan etkileyen kritik bir ön işlemdir. Milyonlarca pikselden oluşan bir görüntünün tamamını derin öğrenme modellerine sokmak yerine, sadece ilgili parçanın olduğu alanı işlemek işlem süresini önemli ölçüde düşürür ve "Arka Plan" kaynaklı gürültüleri (makine parçaları, zemin ışımaları) eleyerek modelin doğruluğunu artırır.

Evrişimsel Sinir Ağları (CNN)

Evrişimsel Sinir Ağları (CNN), derin öğrenme dünyasının "görsel zekâsı" olarak kabul edilir ve kusur tespitinde kullanılan en temel yöntemdir. CNN, bir görüntüyü insan gözüne benzer bir hiyerarşiyle inceler; piksel matrisi üzerinde matematiksel filtreler (Kernel) gezdirerek kenar, köşe ve doku gibi öznitelikleri otomatik olarak çıkarır.



Görüntü Bölütleme (Segmentation) Mimarileri: U-Net ve Autoencoders

Nesne tespitinin ötesinde, kusurun şeklini ve tam sınırlarını belirlemek için segmentasyon mimarileri kullanılır:

U-Net: Görüntüyü piksel seviyesinde sınıflandıran bir mimaridir. Encoder (daraltıcı) ve Decoder (genişletici) yapısı sayesinde, kusurun "nerede" olduğunu piksel hassasiyetinde belirler. Çatlak gibi ince hataların uzunluğunu ve alanını ölçmek için idealdir.

Autoencoders (Oto-kodlayıcılar): Genellikle "Anomali Tespiti" (Unsupervised Learning) için kullanılır. Model sadece sağlam parçalarla eğitilir ve görüntüyü sıkıştırıp tekrar oluşturmaya çalışır. Eğer parça üzerinde bir kusur varsa, model bunu yeniden oluşturamaz ve ortaya çıkan fark (Reconstruction Error) kusur olarak işaretlenir.

Nesne Tespit Algoritmaları: YOLO

YOLO (You Only Look Once), görüntüyü tek bir seferde sinir ağından geçirerek kusurların yerini ve sınıfını aynı anda tespit eden, hız odaklı bir algoritmadır. Görüntüyü izgaralara bölerek çalışan YOLO, saniyede 60-100 kare (FPS) işleyebilmesi sayesinde hızlı akan üretim bantlarında gerçek zamanlı kalite kontrol için endüstri standardı haline gelmiştir.

MATERYAL VE YÖNTEM

Kavramsal Çerçeve: Kalite 4.0 ve Dijital Dönüşüm

Endüstri 4.0 süreciyle birlikte üretim sistemlerinde kalite yönetimi, "Kalite 4.0" olarak adlandırılan yeni bir evreye geçmiştir. Bu yaklaşım; büyük veri, makine öğrenimi, IoT ve bulut bilişim gibi teknolojilerin kalite süreçlerine entegre edilmesini kapsamaktadır. Geleneksel yöntemlerin aksine, Kalite 4.0 stratejisinde yapay zekâ destekli otonom sistemler ve akıllı fabrikalar ön plana çıkmakta; bu sayede hatalı üretim maliyetlerinin düşürülmesi, verimliliğin artırılması ve müşteri memnuniyetinin sağlanması hedeflenmektedir. Bu çalışmada ele alınan yöntemler, bu dijital dönüşümün bir parçası olarak görsel kalite kontrol süreçlerinin otomasyonuna odaklanmaktadır.

Yüzey Karakteristiğine Göre CNN Mimarilerinin Seçimi

Görsel kusur tespitinde kullanılan Evrişimsel Sinir Ağı (CNN) mimarilerinin performansı, incelenen ürünün yüzey özelliklerine (renk, doku, desen) göre değişkenlik göstermektedir. Literatürde metal, ahşap, gıda ve kumaş gibi farklı yüzey türleri üzerinde yapılan karşılaştırmalı analizlerde; GoogleNet, SqueezeNet ve VGG19 gibi mimariler test edilmiştir. Yapılan deneysel çalışmalarda, siyah-beyaz tonlamanın hâkim olduğu metal ve kumaş veri setlerinde GoogleNet mimarisinin daha yüksek başarı sağladığı, buna karşın renk bilgisinin ayırt edici olduğu ahşap ve gıda veri setlerinde VGG19 mimarisinin daha etkili olduğu belirlenmiştir. Bu bulgular, yöntem seçiminde veri setinin renk uzayı ve doku özelliklerinin belirleyici olduğunu ortaya koymaktadır.

Sektörel Uygulamalar ve Özelleştirilmiş Ağ Modelleri Farklı endüstriyel alanların gereksinimlerine göre özelleştirilmiş derin öğrenme modelleri ve transfer öğrenme teknikleri materyal olarak kullanılmaktadır:

- **Ahşap Endüstrisi:** Ahşap yüzeylerdeki kusurların tespiti için ShuffleNet, AlexNet, GoogleNet, MobileNet, DenseNet ve Inception-V3 gibi çeşitli mimariler kıyaslanmıştır. Özellikle Inception-V3 mimarisi, transfer öğrenme yöntemiyle eğitildiğinde %88,41 test doğruluğu ile en başarılı model olarak öne çıkmış ve kalite kontrol sistemleri için uygun bulunmuştur.

- **Gıda Endüstrisi:** Tarımsal ürünlerin kalite kontrolünde, örneğin "Granny Smith" elma çeşidi üzerindeki fiziksel hasarların tespiti için AlexNet, VGG16 ve InceptionV3 modelleri kullanılmıştır. Deney düzeneği ile elde edilen görüntüler üzerinde eğitilen InceptionV3 modeli, 100 çevrim sonunda %100'e yakın test doğruluğu sağlayarak gıda denetiminde etkin bir yöntem olarak belirlenmiştir.

- **Metal ve Kaynak Teknolojileri:** Pil üretimindeki lazer kaynak kalitesinin kontrolü gibi hassas işlemlerde, VGG-16 tabanlı optimize edilmiş modeller kullanılmıştır. Transfer öğrenme teorisine dayalı bu yaklaşım, büyük veri tabanlarında önceden eğitilmiş ağırlıkları kullanarak endüstriyel bilgisayarlar üzerinde %99,87 gibi yüksek bir doğruluk oranına ulaşmıştır.

Karmaşık Yüzeylerde Segmentasyon ve Konumlandırma Metalik yüzeylerde karşılaşılan yansıma, gürültü ve eşit olmayan aydınlatma gibi zorlukları aşmak için sadece sınıflandırma yapan ağlar yerine, kusurun tam konumunu belirleyen segmentasyon temelli yaklaşımlar tercih edilmektedir. Bu kapsamda, kademeli oto kodlayıcı (Cascaded Autoencoder- CASAE) mimarisi geliştirilmiştir. Bu yöntem, giriş görüntüsünü anlamsal segmentasyon yoluyla piksel tabanlı bir maskeye dönüştürmekte ve ardından kompakt bir CNN ile kusur bölgelerini sınıflandırmaktadır. Bu çift aşamalı yapı, özellikle belirsiz kenarlara sahip kusurların tespitinde yüksek hassasiyet sağlamaktadır.

Gömülü Sistemler ve Gerçek Zamanlı Tespit (YOLO) Üretim hatlarında hızın kritik olduğu senaryolarda, gömülü sistemler üzerinde çalışan tek aşamalı nesne tespit algoritmaları materyal olarak kullanılmaktadır. Çelik yüzeylerdeki kusurların tespiti için Jetson Nano gömülü kartı üzerinde YOLOv7 ve YOLOv5 algoritmaları karşılaştırılmıştır. Gömülü sistemlerin çıkarım hızını artırmak amacıyla TensorRT optimizasyon aracı kullanılmış ve sınırlı veri seti problemini aşmak için veri artırma yöntemlerine başvurulmuştur. Yapılan testlerde YOLOv7 modelinin, hem hız (FPS) hem de doğruluk (mAP) açısından gerçek zamanlı endüstriyel uygulamalar için daha uygun olduğu raporlanmıştır.

SONUÇ VE ÖNERİLER

Bu çalışmada, Endüstri 4.0 ve Kalite 4.0 vizyonu çerçevesinde, endüstriyel görsel kalite kontrol süreçlerinde kullanılan derin öğrenme tabanlı kusur tespit yöntemleri incelenmiştir. Metal yüzeyler başta olmak üzere farklı endüstriyel ürünlerdeki hataların tespiti için kullanılan mimariler, donanım altyapıları ve optimizasyon teknikleri değerlendirilmiştir.

Sonuçlar

Yapılan literatür incelemesi ve yöntem analizleri sonucunda şu temel bulgulara ulaşılmıştır:

- Yüksek Doğruluk Oranları:** Transfer öğrenme (Transfer Learning) yöntemiyle önceden eğitilmiş ağırlıkların kullanılması durumunda, derin öğrenme modellerinin endüstriyel bilgisayarlar üzerinde %99,87 gibi yüksek bir doğruluk oranına ulaşabildiği görülmüştür.
- Segmentasyonun Önemi:** Metalik yüzeylerde sıkça karşılaşılan yansıma, gürültü ve düzensiz aydınlatma sorunlarını aşmak için sadece sınıflandırma yapan ağların yeterli olmadığı anlaşılmıştır. Bunun yerine, kademeli oto-kodlayıcı (CASA) gibi segmentasyon temelli mimarilerin, belirsiz kenarlara sahip kusurları tespit etmede daha hassas sonuçlar verdiği belirlenmiştir.
- Gömülü Sistem Performansı:** Gerçek zamanlı üretim hatlarında hızın kritik bir faktör olduğu tespit edilmiştir. Çelik yüzey kusurları üzerinde yapılan karşılaştırmalı analizlerde, YOLOv7 algoritmasının YOLOv5 modeline kıyasla hem hız (FPS) hem de doğruluk (mAP) açısından endüstriyel uygulamalar için daha uygun olduğu sonucuna varılmıştır.
- Uçta İşleme (Edge AI) Başarısı:** NVIDIA Jetson Nano gibi gömülü sistem kartları üzerinde TensorRT optimizasyon aracı kullanıldığında, çıkarım hızının (inference speed) artırılabilirdiği görülmüştür. Bu durum, kalite kontrol süreçlerinin buluta bağımlı kalmadan, doğrudan üretim bandının ucunda düşük maliyetle gerçekleştirilebileceğini kanıtlamaktadır.

Öneriler

Elde edilen sonuçlar ışığında, endüstriyel kalite kontrol sistemlerinin geliştirilmesi ve gelecek çalışmalar için aşağıdaki öneriler sunulmaktadır:

- **Veri Çeşitliliğinin Artırılması:** Derin öğrenme modellerinin başarısı büyük ölçüde veri setine bağlıdır. Sınırlı veri seti problemini (Data Imbalance) aşmak için klasik veri artırma yöntemlerine ek olarak, Üretken Çekişmeli Ağlar (GAN) kullanılarak sentetik kusurlu veri üretimi üzerine çalışmalar yapılmalıdır.
- **Donanım Optimizasyonu:** Gömülü sistemlerin sınırlı kaynaklarını daha verimli kullanmak adına, model sıkıştırma (pruning) ve kuantalama (quantization) tekniklerinin kullanımı yaygınlaştırılmalıdır.
- **Hibrit Modeller:** Karmaşık yüzey hatalarında doğruluğu artırmak için nesne tespiti (YOLO) ve segmentasyon (U-Net/Autoencoder) mimarilerini birleştiren hibrit yapıların kullanılması önerilmektedir.

KAYNAKÇA

- Balta, M. (2024). *Rulman titreşim verilerinden derin öğrenme tabanlı hata tespiti* (Yüksek lisans tezi). Maltepe Üniversitesi, İstanbul.
- Bochkovskiy, A., Wang, C. Y., & Liao, H. Y. M. (2020). YOLOv4: Optimal speed and accuracy of object detection. *arXiv preprint arXiv:2004.10934*.
- Bolatan, G. İ. S. (2020). Kalite 4.0. *Iğdır Üniversitesi Sosyal Bilimler Dergisi*, (21), 437-454.-2154486]
- Cai, N., Cheng, J., & Khan, S. (2021). Deep learning-based visual quality inspection in manufacturing: A survey. *Journal of Manufacturing Systems*, 60, 513-534. <https://doi.org/10.1016/j.jmsy.2021.06.012>
- Çelik, Y., Dengiz, B., & Güney, S. (2023). Ahşap ham maddelerde yüzey hatasını belirlemek için görüntü işleme tabanlı kalite kontrol sistemi. *Mühendislik Bilimleri ve Tasarım Dergisi*, 11(4), 1365-1382.
- Ettalibi, A., Elouadi, A., & Mansour, A. (2024). AI and computer vision-based real-time quality control: a review of industrial applications. *Procedia Computer Science*, 231, 212-220.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.
- Gonzalez, R. C., & Woods, R. E. (2018). *Digital image processing* (4. baskı). Pearson.
- Güçlü, E., Aydın, İ., Şener, T. K., & Akin, E. (2022). Çelik yüzeylerdeki kusurların tespiti için derin öğrenme tabanlı gömülü sistem tasarımı. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 34(2), 521-532.-267681911]
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778.
- Karakaş, B., & Kulluk, S. (2025). Farklı yüzey türlerine sahip ürünlerin hata tespitinde evrimsel sinir ağı mimarilerinin etkisi. *Kahramanmaraş Sütçü İmam Üniversitesi Mühendislik Bilimleri Dergisi*, 28(4), 1673-1687.
- Reshadat, V., & Kapteijns, R. A. (2021, November). Improving the performance of automated optical inspection (AOI) using machine learning classifiers. *In 2021 International Conference on Data and Software Engineering (ICoDSE)* (pp. 1-5). IEEE.
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, 234-241. https://doi.org/10.1007/978-3-319-24574-4_28

- Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning. *Journal of Big Data*, 6(1), 1-48. <https://doi.org/10.1186/s40537-019-0197-0>
- Tao, X., Zhang, D., Ma, W., Liu, X., & Xu, D. (2018). Automatic metallic surface defect detection and recognition with convolutional neural networks. *Applied Sciences*, 8(9), 1575.
- Ünal, Z., Kızıldeniz, T., Özden, M., Aktaş, H., & Karagöz, Ö. (2023). Derin öğrenme teknikleri ile elmada (Granny Smith) kusur tespiti. *Niğde Ömer Halisdemir Üniversitesi Mühendislik Bilimleri Dergisi*, 12(4), 1119-1129.
- Villalba-Diez, J., Schmidt, D., Geier, R., Ordieres-Meré, J., Molina, M., & Wellbrock, W. (2019). Deep learning for industrial computer vision quality control in the printing industry 4.0. *Sensors*, 19(18), 3987. <https://doi.org/10.3390/s19183987>
- Yang, Y., Pan, L., Ma, J., Yang, R., Zhu, Y., Yang, Y., & Zhang, L. (2020). A high-performance deep learning algorithm for the automated optical inspection of laser welding. *Applied Sciences*, 10(3), 933.



Muhammed Arda Sarı, 2006 yılında İstanbul’da doğdu. Lise eğitimini Sultangazi Anadolu Lisesi’nde tamamladı. Halen Sakarya Uygulamalı Bilimler Üniversitesi, İmalat Yürütme Sistemleri Operatörlüğü programında 2. sınıf öğrencisi olarak eğitimine devam etmektedir. İlgili alanları arasında üretim sistemleri, endüstriyel otomasyon ve yazılım geliştirme bulunmaktadır.



Mehmet Ceran, 2006 yılında Konya’da doğdu. Lise eğitimini Çumra Atatürk Anadolu Lisesi’nde tamamladı. Halen Sakarya Uygulamalı Bilimler Üniversitesi, İmalat Yürütme Sistemleri Operatörlüğü programında 2. sınıf öğrencisi olarak eğitimini sürdürmektedir. Çalışma ve ilgi alanları arasında nesnelerin interneti (IoT), akıllı fabrika uygulamaları ve üretimde veri analitiği yer almaktadır.